
Union-web


AI 수어 인식 기반 실시간 화상회의 플랫폼

청각장애인과 비장애인이 자막 없이도 자연스럽게 소통할 수 있는 화상회의 서비스

프로젝트 개요

- ▶ 문제의식: 수어를 모국어로 쓰는 사람과 그렇지 않은 사람 사이에는 통역 인력 없이는 소통이 제한되는 순간이 많음 (교실, 병원, 목소리를 낼 수 없는 위급 상황 등)
- ▶ 목표: 수어 <-> 텍스트/음성을 양방향으로 번역하는 AI 기술을 기반으로, 화상회의·실시간 통역·수어 학습·긴급 신고 등 다양한 상황에서 쓸 수 있는 다목적 소통 플랫폼
- ▶ 핵심 가치
 - 실시간성 - 대화 흐름을 끊지 않고 즉시 번역/자막 생성
 - 접근성 - 별도 장비 없이 웹캠 + 브라우저만으로 사용 가능
 - 확장성 - 지문자(자모) 단위뿐 아니라 단어 단위 수어까지 함께 인식하도록 개발 중

전체 시스템 구성도



- ▶ 각 참가자의 카메라 프레임을 서버로 전송 -> 서버에서 MediaPipe로 손 랜드마크 추출
- ▶ 10프레임 시퀀스를 LSTM 모델에 입력해 자모(지문자) 예측
- ▶ 예측된 자모를 음절로 조합해 실시간 자막(sign_progress)과 완성 문장(sign_result)으로 송출
- ▶ 무거운 연산(MediaPipe/TensorFlow)은 별도 스레드(eventlet tpool)에서 처리해 여러 참가자가 동시에 접속해도 서버가 멈추지 않도록 구성

KEY FEATURES

핵심 기능

긴급 신고

AI가 수어 인식을 바탕으로 신고 내용과 위치를 119/112에 전달

실시간 화상회의

WebRTC 기반 1:1 화상통화, 음성/영상 On-Off

실시간 채팅

텍스트 및 파일 공유 채팅

실시간 수어 자막

손 모양을 인식해 자동으로 한글 자막 생성 및 상대방에게 전송

수어 인식 파이프라인 상세

- 1 카메라 프레임 캡처 (약 35fps, 브라우저 -> 서버 전송)
- 2 MediaPipe로 오른손 21개 랜드마크 추출
- 3 관절 벡터 20개 + 관절 각도 15개 = 55차원 특징 벡터 계산
- 4 10프레임 시퀀스로 누적
- 5 LSTM 모델로 자모(31개 클래스 중 1개) 예측 + 신뢰도 확인
- 6 자음/모음 전환 감지 시 직전 음운을 확정 -> 음절 조합 (join_jamos)
- 7 완성된 단어를 문장으로 묶어 실시간 자막으로 상대방에게 전송

자모 -> 음절 조합 큐 알고리즘

LSTM은 프레임마다 자음/모음 낱자 1개만 예측 -> 한글은 초성+중성(+종성)이 하나의 음절로 합쳐져야 읽을 수 있으므로, 이를 조합하는 상태 기계가 필요하다 (app.py on_sign_frame)

세션별 상태값 4가지

- ▶ pending: 지금 손모양이 유지 중인, 아직 확정되지 않은 자모 1개
- ▶ queue: 자음<->모음 전환이 감지되어 확정된 자모 리스트 (단어 1개분)
- ▶ sentence_words: 손이 멈춰 완성된 단어들의 리스트
- ▶ candidate_state: 오인식 디바운스용 (후보 자모, 연속 프레임 수)

핵심 로직

- ▶ 새 단어는 항상 초성(자음)으로 시작 -> 큐가 비어있을 때 모음이 예측되면 무시
- ▶ 자음<->모음 전환 감지 시: pending을 queue에 편입하고 새 예측값이 새 pending이 됨
- ▶ 같은 타입(자음<->자음, 모음<->모음)끼리는 후보만 갱신되고 큐에는 안 쌓임
- ▶ 같은 자모가 N프레임 연속 나와야 확정 (전환 구간에서 스치는 오인식 방지)
- ▶ 손 인식이 일정 시간 끊기면 pending까지 큐에 편입 -> 음절 조합 -> 문장으로 송출

왜 YOLO가 아닌 LSTM 시퀀스 모델인가

- ▶ 초기에는 YOLO 기반 전이학습(객체 탐지)으로 손모양을 인식하는 방식을 검토함
- ▶ 그러나 YOLO는 정지된 한 프레임 안에서 바운딩박스로 손 모양을 탐지하는 방식이라, 실시간 영상에서 이어지는 손동작의 시간적 흐름(시퀀스)을 반영하지 못함
- ▶ 화상회의처럼 끊김 없는 실시간 처리가 핵심인 서비스에는, 프레임 간 흐름을 학습하는 LSTM 기반 시퀀스 모델이 더 적합하다고 판단해 채택

현재 상태

- ▶ 현재 배포된 인식 모델은 파이프라인 검증을 위해 공개된 모델을 가져와 연동한 것으로, 자체 데이터로 학습한 모델이 아님
- ▶ 지문자(자음/모음) 31종만 인식 가능 - 실제 대화에 필요한 단어/문장 단위 수어는 아직 지원하지 않음
- ▶ 따라서 다음 단계로 자체 데이터셋을 구축하고 모델을 직접 학습시키는 과정이 필요함

기술적 한계

- ▶ 시퀀스 대기 지연: LSTM 모델은 10프레임이 모여야 예측하므로, 사용자가 손모양을 유지한 채 잠시 기다려야 함
 - 이론상 35fps면 약 0.3초면 충분하지만, 실제로는 프레임 캡처 후 서버로 전송하는 통신 시간이 더해져 체감 지연이 발생
- ▶ 자모 조합 알고리즘의 한계: 실시간 영상 특성상 손이 다음 동작으로 이동하는 전환 구간에서, 사용자가 의도하지 않은 자모가 순간적으로 인식되는 경우가 있음
- ▶ 모델 자동 전환 로직 부재: 사용자가 지금 지문자(자음/모음)로 표현 중인지 단어로 표현 중인지 시스템이 스스로 판단하는 로직이 없음 - 음운/단어 두 모델을 각각 만들어도, 어느 시점에 어떤 모델을 써야 할지 자동으로 결정할 수 없어 실사용 관점에서 아직 실효성이 떨어짐
- ▶ 팀 구성의 한계: 팀 전원이 모델 학습 경험이 전무한 1학년으로 구성되어, 학습에 필요한 하이퍼파라미터(신뢰도 임계값, 시퀀스 길이, epoch 수 등)를 충분한 근거 없이 시행착오로 정해야 했음

자체 데이터셋 구축 및 모델 학습

수어 방식에 따라 서로 다른 특징과 구조를 갖는 2가지 모델을 별도로 학습한다

① 음운(지문자) 인식 모델

- ▶ 대상: 자음/모음 낱자 31종
- ▶ 입력: 오른손 21개 랜드마크 (55차원 특징, 10프레임 시퀀스)
- ▶ 구조: LSTM(64) -> Dropout -> Dense(32) -> Dense(softmax)

② 단어 인식 모델

- ▶ 대상: 나는 / 맛있다 / 고양이 / 식사 등 단어 단위 수어
- ▶ 입력: 양손 21점x2 + 어깨·팔꿈치·손목 6점 (150차원 특징, 30프레임 시퀀스)
- ▶ 구조: LSTM(64,seq) -> LSTM(64) -> Dropout -> Dense(32) -> Dense(softmax)

데이터 수집 방법 2가지

방법 1. 직접 촬영

- ▶ 웹캠으로 클래스별 영상을 직접 녹화
- ▶ MediaPipe로 랜드마크 추출 후 시퀀스(npy)로 변환
- ▶ 소규모 클래스 확장, 특정 상황 데이터 보강에 적합

방법 2. AIHub 공개 데이터

- ▶ AIHub "수어 영상" 데이터셋 활용
- ▶ 지화 1,000종 + 수어 단어 3,000종 + 수어 문장 2,000종, 형태소 단위 라벨링 제공
- ▶ 대규모 데이터 확보로 모델 일반화 성능 향상에 활용

텍스트·음성 → 수어 애니메이션 변환

- ▶ 현재는 수어 -> 텍스트(자막) 방향만 지원
- ▶ 반대 방향으로, 입력된 텍스트 또는 음성을 3D 아바타의 수어 동작으로 변환하는 기능을 계획
- ▶ 청각장애인이 상대방의 말(텍스트/음성)을 수어 애니메이션으로 시각적으로 확인 가능
- ▶ -> 화상회의 내 양방향(수어 ↔ 텍스트/음성) 실시간 번역 완성

음성 → 전사문(STT) 변환

- ▶ 상대방(비장애인)의 음성을 실시간 음성인식(STT)으로 텍스트化
- ▶ 생성된 전사문은 자막으로 표시하거나, 향후계획 2(수어 애니메이션 변환)의 입력으로 사용
- ▶ 결과적으로 '음성 -> 전사문 -> 수어 애니메이션'으로 이어지는 파이프라인의 첫 단계

단어 나열 → 자연스러운 문장 변환

- ▶ 수어는 조사·어미 없이 핵심 단어만 순서대로 나열하는 방식으로 표현되는 경우가 많음
- ▶ 예) “나 / 학교 / 가다” 처럼 인식된 단어열은 그 자체로는 자연스러운 한국어 문장이 아님
- ▶ 인식된 단어열을 자연어 생성(언어 모델)을 통해 조사·어미가 포함된 자연스러운 문장으로 재구성하는 장치가 필요
- ▶ 예) “나 학교 가다” -> “저는 학교에 갑니다”

수어 → 음성 변환 장치

- ▶ 인식된 수어 자막(문장)을 음성(TTS)으로 변환해 상대방에게 들려주는 기능도 함께 검토 중
- ▶ 화상회의뿐 아니라 오프라인 대면 상황에서도 활용 가능한 방향으로 확장 고려
- ▶ 구체적인 설계는 앞선 4가지 향후계획 이후 순차적으로 진행 예정

전체 로드맵 요약

현재

지문자 인식 (외부 모델) + 화상회의/채팅

1단계

자체 데이터셋 구축 및 음운/단어 모델 학습

2단계

음성 → 전사문(STT) 및 자연스러운 문장 변환

3단계

텍스트·음성 → 수어 애니메이션 변환 (양방향 번역 완성)

4단계

수어 → 음성 변환 장치 검토

부록: Union-web 폴더 구조

<code>app.py</code>	Flask+Socket.IO 서버 - 라우팅, 회원 DB, 수어 인식(MediaPipe+LSTM), 자모 조합 로직
<code>requirements.txt</code>	의존 패키지 목록 (Flask, mediapipe, tensorflow 등 버전 고정)
<code>unicode.py</code>	자모 결합/분리 유틸 (join_jamos 등)
<code>gesture_classifier.h5</code>	배포된 지문자 인식 LSTM 모델 (외부에서 가져온 모델)
<code>modules/hand_module.py</code>	MediaPipe HandLandmarker 래퍼 (오른손 랜드마크 검출)
<code>modules/utlis.py</code>	손 랜드마크 -> 55차원 특징 벡터 변환(Vector_Normalization)
<code>models/hand_landmarker.task</code>	MediaPipe 손 검출 모델 번들 파일
<code>database/users.xlsx</code>	회원 정보 저장 엑셀 DB
<code>templates/index.html</code> 등	랜딩/회원가입/계정찾기/소개 페이지
<code>templates/chatentry.html</code>	화상회의 입장 전 대기실 (카메라 미리보기)
<code>templates/room.html</code>	화상회의방 - WebRTC 화상통화 + 실시간 자막
<code>static/js/room_ui.js</code>	화상회의방 클라이언트 - WebRTC, 프레임 캡처/전송, 자막 표시
<code>static/js/chatentry.js</code>	입장 전 카메라/마이크 미리보기 로직
<code>static/js/auth.js</code> 등	로그인/회원가입/계정찾기 클라이언트 로직

부록: KSL-Model-Training 폴더 구조

<code>README.md</code>	프로젝트 사용법 전체 안내
<code>requirements.txt</code>	의존 패키지 (mediapipe, tensorflow, scikit-learn 등)
<code>download_mediapipe_models.py</code>	MediaPipe HolisticLandmarker 모델 번들 다운로드
<code>modules/holistic_module.py</code>	MediaPipe HolisticLandmarker 래퍼 (양손+pose 검출)
<code>modules/utils.py</code>	음운용(55차원)/단어용(150차원) 특징 추출 함수
<code>phoneme_model/config.py</code>	음운 모델 설정 (31개 클래스, 시퀀스 길이 10 등)
<code>phoneme_model/record_dataset.py</code>	[방법1] 웹캠으로 지문자 영상 직접 녹화
<code>phoneme_model/build_dataset_from_videos.py</code>	녹화 영상 -> 학습용 시퀀스(npz) 변환
<code>phoneme_model/build_dataset_from_aishub.py</code>	[방법2] AIHub 공개 데이터 -> 시퀀스 변환
<code>phoneme_model/train.py</code>	음운 인식 LSTM 모델 학습
<code>phoneme_model/test_webcam.py</code>	웹캠으로 음운 모델 실시간 테스트
<code>word_model/*.py</code>	위와 동일 구성 - 단어 인식 모델용 (150차원, 30프레임 시퀀스)

감사합니다

Union-web Team